EE412 Foundation of Big Data Analytics, Fall 2021 HW2

Name: 노현섭

Student ID: 20190220

Discussion Group (People with whom you discussed ideas used in your answers):

On-line or hardcopy documents used as part of your answers:

[TOKEN=1]

Answer to Problem 1

badger

badger

badger

badger

badger

banana

nanana

Answer to Problem 2

Exercise 11.1.7

```
import numpy as np
     M = np.array([[1,1,1],[1,2,3],[1,3,6]])
     for i in range(3):
       x = np.ones((3,1))
       tmp = np.zeros((3,1))
       while(np.linalg.norm(x-tmp) > 0.0001):
         tmp = x
10
         product = np.dot(M, x)
11
         x = product / np.linalg.norm(product)
       eig_value = np.dot(np.dot(np.transpose(x), M), x)
12
13
       M = M - eig_value*np.dot(x, np.transpose(x))
       print ("eig_value: %f") % eig_value
14
15
       print (x)
       print (M)
16
```

```
(a)
[[ 0.19382449]
 [ 0.4722482 ]
 [ 0.85989168]]
(b)
eigenvalue: 7.872983
(c)
[[ 0.70422829  0.27936011 -0.31217491]
 [\ 0.27936011\ \ 0.24418012\ -0.19707919]
 [-0.31217491 \ -0.19707919 \ \ 0.17860824]]
(d)
Second eigenpair
eigenvalue: 1.000000
eigenvector: [[ 0.81649467]
              [ 0.40823775]
              [-0.40826264]]
(e)
Thread eigenpair
eigenvalue: 0.127017
eigenvector: [[ 0.54382585]
              [-0.78123612]
```

[0.30646952]]

Exercise 11.3.1

```
import numpy as np
     M = np.array([[1,2,3],[3,4,5],[5,4,3],[0,2,4],[1,3,5]])
     # (a) Compute MTM and MMT.
     MTM = np.dot(np.transpose(M), M)
     MMT = np.dot(M, np.transpose(M))
     print (MTM)
     print (MMT)
11
     # (b) Compute eigenpairs of MTM and MMT.
     print ("eigenpair of MTM")
12
13
     MTM_pair = np.linalg.eig(MTM)
     print (MTM_pair)
14
     print ("eigenpair of MMT")
     MMT_pair = np.linalg.eig(MMT)
17
     print (MMT_pair)
     # (c) Find SVD (assume all eigenvalues are different)
     rank = np.linalg.matrix_rank(M)
21
     print ("This is rank")
22
     print (rank)
23
     eig_values = []
     V = np.zeros((M.shape[1], rank))
     U = np.zeros((M.shape[0], rank))
25
26
     values = list(MTM_pair[0])
     # print MTM_pair[1]
30
     for i in range(rank):
       index = values.index(max(values))
       eig_values.append(values[index])
       values[index] = 0
       V[:,i] = MTM_pair[1][:,index]
     if V[0,0] < 0:
      V = -V
     # Find U, which is matrix of eigenvectors of MMT
40
     values = list(MMT_pair[0])
```

```
# Find U, which is matrix of eigenvectors of MMT
     values = list(MMT pair[0])
     for i in range(rank):
       index = values.index(max(values))
       values[index] = 0
       U[:,i] = MMT_pair[1][:,index]
     if U[0,0] < 0:
     U = -U
     sigma = np.sqrt(np.diag(eig_values))
     print ("U,V,S of M")
     print (U)
     print (V)
     print (sigma)
     U_1 = U[:,:-1]
     V_1 = V[:,:-1]
     sigma_1 = sigma[:-1,:-1]
     print ("Approximated U,V,S")
     print (U_1)
     print (V_1)
     print (sigma_1)
62
     # (e) Compare energy of the original and approximation
     print ("Original energy: %f") % (np.sum(np.square(sigma)))
     print ("Approximated energy: %f") % (np.sum(np.square(sigma_1)))
```

```
(a) [[36 37 38] [[14 26 22 16 22]]

M'M [37 49 61] MM' [26 50 46 28 40]

[38 61 84]] [22 46 50 20 32]

[16 28 20 20 26]

[22 40 32 26 35]]
```

```
- MM'
  eigenvalues: [ 1.53566996e+02, -1.03322028e-14, 1.54330035e+01,
     2.54653026e-15, -3.61063094e-15]
  eigenvector: [[ 0.29769568, 0.94131607, -0.15906393, 0.12508859, 0.07520849],
              [0.57050856, -0.17481584, 0.0332003, -0.45318832, -0.07287035],
             [0.52074297, -0.04034212, 0.73585663, 0.32553276, -0.10566284],
              [0.32257847, -0.18826321, -0.5103921, 0.72000366, -0.72571726],
              [0.45898491, -0.21515796, -0.41425998, -0.39318742, 0.67171677]]
(c)
SVD of M
- U
       [[ 0.29769568 -0.15906393]
       [ 0.57050856  0.0332003 ]
       [ 0.52074297  0.73585663]
       [ 0.32257847 -0.5103921 ]
       [ 0.45898491 -0.41425998]]
       [[ 0.40928285  0.81597848]
       [ 0.56345932  0.12588456]
       [ 0.7176358 -0.56420935]]
- Sigma
       [[ 12.39221516 0.
                 3.92848616]]
       [ 0.
(d)
 One-dimensional approximation
 - U
        [[ 0.29769568]
        [ 0.57050856]
        [ 0.52074297]
        [ 0.32257847]
        [ 0.45898491]]
    V
        [[ 0.40928285]
        [ 0.56345932]
        [ 0.7176358 ]]
    Sigma: 12.3922151555
(e)
Compare evergy
    Original evergy: 169
    Retained evergy: 153.566996
```

Retained 90.868%

Answer to Problem 3

(a) Solve the following problems.

Exercise 9.3.1

a. Compute the Jaccard distance between each pair of users.

New matrix

	a	b	c	d	e	f	g	h
A	1	1	0	1	1	0	1	1
В	0	1	1	1	1	1	1	0
С	1	0	1	1	0	1	1	1

distance (A, B) =
$$4/8 = 1/2$$

distance (B, C) =
$$4/8 = 1/2$$

distance (A, C) =
$$4/8 = 1/2$$

b. Compute cosine distance.

distance (A, B) =
$$\frac{4}{\sqrt{6} \times \sqrt{6}} = \frac{4}{6} = \frac{2}{3}$$

distance (B, C) =
$$\frac{4}{\sqrt{6} \times \sqrt{6}} = \frac{4}{6} = \frac{2}{3}$$

distance (A, C) =
$$\frac{4}{\sqrt{6} \times \sqrt{6}} = \frac{4}{6} = \frac{2}{3}$$

c. Repeat (a), treating 3, 4, and 5 as 1 and 1, 2, and blank as 0.

New matrix

	a	b	c	d	e	f	g	h
A	1	1	0	1	0	0	1	0
В	0	1	1	1	0	0	0	0
С	0	0	0	1	0	1	1	1

distance (A, B) =
$$1 - 2/5 = 3/5$$

distance (B, C) =
$$1 - 1/6 = 5/6$$

distance (A, C) =
$$1 - 2/6 = 2/3$$

d. Repeat (b) with new utility matrix from c.

distance (A, B) =
$$\frac{2}{2 \times \sqrt{3}} = 1/\sqrt{3}$$

distance (B, C) =
$$\frac{1}{\sqrt{3} \times 2} = \frac{1}{2\sqrt{3}}$$

distance (A, C) = $\frac{2}{2 \times 2} = 1/2$

distance (A, C) =
$$\frac{2}{2 \times 2}$$
 = 1/2

e. Normalize the matrix.

New Matrix

	a	b	c	d	e	f	g	h
A	0.666667	1.666667		1.666667	-2.3333		-0.3333	-1.3333
В		0.666667	1.666667	0.666667	-1.3333	-0.3333	-1.3333	
С	-1		-2	0		1	2	0

f. Compute cosine distance with (e).

distance (A, B) =
$$\frac{5.777778}{3.651484 \times 2.708013} = 0.584307$$

distance (B, C) = $\frac{-6.33333}{2.708013 \times 3.162278} = -0.73957$
distance (A, C) = $\frac{-1.33333}{3.651484 \times 3.162278} = -0.11547$

■ Exercise 9.3.2

a. Cluster the eight items hierarchically into four clusters.


New matrix

	a	b	c	d	e	f	g	h
A	1	1	0	1	0	0	1	0
В	0	1	1	1	0	0	0	0
С	0	0	0	1	0	1	1	1

Jaccard distance

	b	c	d	e	f	g	h
a	1/2	1	2/3	1	1	1/2	1
h	1	1	2/3	1	0	1/2	
g	2/3	1	1/3	1	1/2		
f	1	1	2/3	1			
e	1	1	1				
d	1/3	2/3					
c	1/2						

Clustering (Assume we break ties lexicographically)



Clusters

$${a, b, d, g}, {c}, {e}, {f, h}$$

b. Construct new matrix

New matrix

	{a, b, d, g}	{c}	{e}	{f, h}
A	17/4		1	2
В	7/3	4	1	2
С	10/3	1		3.5

c. Compute cosine distance from (b)

distance (A, B) =
$$\frac{14.91667}{4.802343 \times 5.142416} = 0.60402$$

distance (B, C) = $\frac{18.7778}{5.142416 \times 4.935698} = 0.739824$
distance (A, C) = $\frac{21.16667}{4.802343 \times 4.935698} = 0.892999$

3-c

Algorithm:

우선 초기 데이터베이스는 딕셔너리 형태로, 일반 데이터와 테스트 데이터를 분리하여 정리하였다. 이때 각각의 유저가 첫번째 key 로 들어가며, 두번째 key 들은 영화 리스트이고 각각 score 가 value 가 된다. 테스트 데이터셋은 세개의 세개의 user, item, time 이 튜플을 이루며 key 값이 되며, value 값은 최종적으로 score 가 된다.

이후 일반 데이터를 normalize 하여 cosine distance 를 구해 각각의 유저(첫 번째 key) 안에 새로운 key 인, 자신과 비슷한 user 를 총 300 명 내림차순으로 정리한다. 각각의 value 는 cosine distance 가 된다. 이 similar user set 을 통해 테스트 데이터 셋에서 각각의 user(튜플의 첫번째 값)와 비슷한 user 목록을 iterate 하게 되고, similarity 및 각각의 유저(300)가 item(튜플의 두번째값)을 평가한 목록을 score 로 낸다. (이때 cosine distance 값을 이용해 적절한 scale 에 차이를 준다.) 만약에 300 명의 유저 중에서 평가한 사람이 없다면, 초기 유저로 돌아가 자신이 내린 전체 영화 평점을 평균화 하여 대체한다.

Item 목록에 대해서도 동일한 방식으로 해주면 전체 score list 가 총 두개가 나온다. (코드에서는 movRate, movRate2 라 명시되어 있다. 이 값들을 적절한 scaler 로 (여기서는 2,5 의 비중을 주었다.) 분배해 최종 계산을 하면 (user, item, time)에 대한 예상 rate 가 나온다.